



Géodata
Paris
l'école des ingénieur-es géographes

Analyse des données Licence Pro 2026-2027

TD n°2- L'analyse univariée

Florian Bayer



OBJECTIF DU TD 2

Les objectifs de ce TD sont de mettre en application les acquis du cours 2 sur l'analyse d'une série de données

- avec des graphiques
- les valeurs centrales
- les paramètres de dispersion

Vous apprendrez à utiliser un outil d'analyse de données : Orange

ORANGE : PRÉSENTATION

Orange est un logiciel open source dédié à l'analyse de données, à l'exploration visuelle et à l'apprentissage automatique.

Basé sur des packages Python pour les analyses, son interface graphique intuitive permet de construire des **flux de travail** ou workflow, sans avoir à écrire de code.

Contrairement à Excel et comme lorsque l'on utilise du code, l'avantage d'Orange est de pouvoir relancer chaque étape du calcul pour le vérifier ou le modifier.

La vue principale d'Orange ressemble à une toile vide où vous pouvez commencer à ajouter des **widgets** pour créer un **workflow**.


A gauche la zone de widgets, à droite l'espace de travail.

The screenshot shows the Orange3 software interface. On the left is the 'Widget Palette' with a search bar and categories: Data, Transform, Visualize, Model, Evaluate, and Unsupervised. The 'Data' category is selected, showing widgets like File, CSV File Import, Datasets, SQL Table, Data Table, Paint Data, Data Info, Rank, Edit Domain, Color, Feature Statistics, and Save Data. On the right is the 'Canvas' where a workflow is being built. It consists of a 'File' widget connected to a 'Data Table' widget via a 'Data' channel. Red arrows point to the widgets with French annotations: 'Un widget de fichier. Double-cliquez pour l'ouvrir et sélectionner le fichier de jeu de données.' for the File widget; 'Un widget de tableau de données. Double-cliquez sur l'icône pour voir les données dans une feuille de calcul.' for the Data Table widget; 'La sortie du tableau de données pour envoyer les données (lignes) sélectionnées au widget.' for the dashed output port of the Data Table; 'La sortie du widget de fichier.' for the output of the File widget; 'L'entrée du widget de tableau de données.' for the input of the Data Table; and 'Le canal de communication. Il transfère le jeu de données du widget de fichier au tableau de données.' for the Data channel. A green arrow points to the dashed output port of the Data Table with the text: 'Cette sortie n'est pas utilisée, d'où la ligne pointillée. Vous pouvez ajouter un autre tableau de données en cliquant sur son icône dans la boîte à outils à gauche, connecter la sortie du tableau de données à l'entrée du nouveau tableau de données (1) et vérifier si les données sélectionnées dans le tableau de données sont bien envoyées au widget en aval. Cette démonstration fonctionne mieux si les deux widgets sont ouverts, c'est-à-dire que leurs fenêtres sont affichées.'

ORANGE : LES WIDGETS

Les widgets sont des modules préconfigurés qui permettent d'importer, de traiter, d'analyser et de visualiser des données. À gauche de l'écran se trouve une barre d'outils avec les catégories de widgets comme :



- Data : Chargement, transformation, filtrage des données
- Visualize : Graphiques et visualisations
- Model : Apprentissage automatique (classification, régression)
- Evaluate : Validation de modèles



ORANGE : CHARGEMENT DES DONNÉES

Le chargement des données se fait à travers le widget "File" dans la catégorie "Data". Il vous permet d'importer des fichiers sous différents formats, y compris CSV ou Excel

- Ajoutez le widget "File" : Glissez-déposez le widget *File* depuis la barre d'outils dans l'espace de travail.
- Sélectionnez le fichier : Cliquez sur le widget "File" puis ouvrez **hdi-edu.xlsx**. Vérifiez que vous avez bien la feuille de calcul Data
- Orange détermine seul chaque type de données, mais vous pouvez les modifier manuellement via la colonne **Type**
- Fermez le widget *File*



- Dans la catégorie Data, sélectionnez et faites glisser le widget Data Table
- A l'aide de la souris, connectez la sortie du widget *File* à l'entrée du widget *Data Table*
- Vous pouvez voir maintenant le contenu des données via le widget *Data Table*
- Comme ils sont liés, tous changements dans le widget *File* entraînera une modification dans le widget *Data Table*
- Vous pouvez sélectionner des lignes dans *Data Table*, mais cela aura aussi un impact sur les futurs calculs. Ils ne se feront que sur les lignes sélectionnées

The screenshot shows the Orange3 software interface. On the left, the 'Data' widget category is open, displaying various widgets like File, CSV File Import, Datasets, SQL Table, Data Table, Paint Data, Data Info, Rank, Edit Domain, Color, Feature Statistics, and Save Data. On the right, a workflow diagram shows a 'File' widget connected to a 'Data Table' widget via a 'Data' link. Red arrows indicate the connection points. Below the workflow, the 'Data Table - Orange' widget is shown with its configuration panel and a data preview table.

Data Table - Orange

Info

- 188 instances
- 46 features (11.6 % missing data)
- No target variable.
- 2 meta attributes

Variables


- ☒ Show variable labels (if present)
- ☐ Visualize numeric values
- ☒ Color by instance classes

Selection

- ☒ Select full rows

	pays	code	revenu_niveau
1	Norway	NOR	Revenu élevé
2	Australia	AUS	Revenu élevé
3	Switzerland	CHE	Revenu élevé
4	Germany	DEU	Revenu élevé
5	Denmark	DNK	Revenu élevé
6	Singapore	SGP	Revenu élevé
7	Netherlands	NLD	Revenu élevé
8	Ireland	IRL	Revenu élevé
9	Iceland	ISL	Revenu élevé
10	Canada	CAN	Revenu élevé

- Ajoutez le widget *Feature Statistics*, toujours dans la catégorie Data.
- Connectez le à la sortie de *Data Table*
- Un histogramme, des valeurs centrales et des paramètres de dispersion sont disponibles
- Notez que Dispersion correspond au coefficient de variation pour les données quantitatives
- Attention, pensez à vérifier que vous n'avez pas de ligne sélectionnée dans Data Table, sinon les calculs de *Feature Statistics* seront uniquement fait sur votre sélection
- Notez que vous pouvez appliquer une couleur aux histogrammes pour les distinguer à l'aide d'une variable qualitative. Par exemple par continent.



Faites l'analyse univariée de la variable **esperance_vie**. Que pouvez-vous en conclure ?

ORANGE : HISTOGRAMME

- A partir de la catégorie Visualize, ajoutez le widget *Distributions*.
- Connectez le à la sortie de *Data Table*
- Les données qualitatives (Category) sont représentées par un diagramme en bâton
- Les données quantitatives par un histogramme
- Pour ce dernier, vous pouvez modifier le nombre de *bins*

Comme précédemment, vous pouvez appliquer une catégorie pour découper l'histogramme selon les modalités de cette dernière. Pour la variable **esperance_vie**, faites un split par **transition_epi**. Que pouvez-vous en conclure ? N'oubliez pas de consulter les métadonnées (onglet Meta du fichier Excel) pour plus de détails




ORANGE : BOX PLOT

- Ajoutez maintenant un Box Plot.
- Connectez le à la sortie de *Data Table*

Analysez la distribution de **taux_fertilite**, puis faites un sous-groupe avec *transition_demo*.

Que pouvez-vous en conclure ?

Pensez à sauvegarder votre projet Orange,
nous le réutiliserons pour le TD 5



ORANGE : ANALYSE COMPARATIVE

Consignes :

1. Formez des binômes
2. Analysez la variable `esperance_vie` avec Feature Statistics et Box Plot

Étape 1 - Vue d'ensemble :

- Analysez les **moyennes** et **écart-types** pour chaque continent (split)
- Utilisez le **Box Plot** avec split par **Continent** pour comparer l'Afrique aux autres continents
- Que révèle ces analyses ?

Étape 2 - Analyse par pays africains :

- Maintenant et l'aide d'un nouveau flux, faites l'analyse pour les pays africains
- Identifiez les pays avec les `esperance_vie` extrêmes (outliers + min/max)
- Choisissez 2 pays opposés pour votre analyse.

SITUER LES PAYS EXTRÊMES

À partir de votre analyse des pays africains, vous allez **décrire** vos deux pays opposés en les situant dans la distribution des autres variables.

Étape 3 - Identifier les cas extrêmes :

- Pays avec la plus haute espérance de vie :
- Pays avec la plus basse espérance de vie :
- Outliers détectés (si il y en a) :

Étape 4 - Dresser le profil des deux pays :

Choisissez 4 ou 5 autres variables (économiques, sociales, sanitaires ; l'onglet **Meta** décrit les indicateurs). Pour chacune, situez vos deux pays parmi les pays africains à l'aide de **Feature Statistics** et du **Box Plot** : au-dessus ou au-dessous de la médiane ? Dans quel quartile ? Est-ce un outlier ?

PROFIL DES PAYS : TABLEAU À COMPLÉTER

Variable	Médiane (Afrique)	Pays 1	Position	Pays 2	Position
esperance_vie					
.....					
.....					
.....					
.....					

Position : 1er, 2e, 3e ou 4e quartile, ou outlier.

Étape 5 - Des questions pour la suite :

- Pour quelles variables vos deux pays s'opposent-ils le plus ?
- Pour lesquelles sont-ils proches, malgré des espérances de vie très différentes ?

Notez ces pistes : vous ne pouvez pas encore conclure, deux pays ne suffisent pas à établir un lien entre deux variables. Nous les testerons sur l'ensemble des pays au cours 5.

RESTITUTION COLLECTIVE

Tour de table : Chaque binôme présente en 1 minute :

- Leurs deux pays extrêmes et leur profil
- La variable pour laquelle ils s'opposent le plus
- Une découverte surprenante dans les données

Questions de débriefing :

- Quelles variables distinguent le plus souvent les pays extrêmes ?
- Certains pays sont-ils atypiques (outliers) pour plusieurs variables à la fois ?
- Peut-on affirmer qu'une variable « explique » l'espérance de vie à partir de deux pays ?

Synthèse pédagogique :

- **Dispersion** : L'écart-type révèle des sous-groupes de pays avec des profils similaires
- **Position** : Une valeur ne prend son sens que située dans une distribution (médiane, quartiles, outliers)
- **Contextualisation** : Les chiffres racontent des histoires humaines et géographiques
- **Démarche scientifique** : Observer, décrire, puis formuler des questions à tester
- **Prudence** : Deux pays ne font pas une règle. Pour savoir si deux variables varient ensemble, il faudra mesurer leur relation sur l'ensemble des pays

Compétences techniques :

- Charger et manipuler des données dans Orange
- Calculer et interpréter les mesures de tendance centrale (moyenne, médiane)
- Calculer et interpréter les mesures de dispersion (écart-type, coefficient de variation)
- Créer et analyser différents types de graphiques (histogrammes, box plots)
- Comparer des distributions entre groupes (continents)

Compétences analytiques :

- Décrire le profil d'un individu à partir de plusieurs variables
- Identifier les valeurs extrêmes et aberrantes (outliers)
- Comprendre qu'une moyenne cache des disparités (importance de l'écart-type)
- Contextualiser les résultats statistiques avec des connaissances géographiques
- Situer un individu dans une distribution (médiane, quartiles, outliers)

Vous avez repéré des variables pour lesquelles les pays extrêmes s'opposent. Pour savoir si ces variables évoluent réellement ensemble sur l'ensemble des pays, il faudra mesurer leur relation : ce sera l'objet du cours 5 sur la corrélation. D'ici là, les cours 3 et 4 porteront sur la cartographie de ces données.